Optimisation Thermique par Apprentissage par Renforcement

Soufiane Najari

Encadré par Pascal Yim

Mars 2026 — Parcours SDI — École Centrale de Lille

1. Contexte : L'Enjeu Énergétique du Bâtiment

Le secteur résidentiel-tertiaire

- **40%** de la consommation énergétique mondiale
- Le CVC représente **50%** de cette part
- Objectif européen : -55% d'émissions d'ici 2030

La limite des contrôleurs actuels

- Systèmes **réactifs** : ignorent la météo
- Réglages **statiques** : gains mal calibrés
- **Indépendants** : ignorent les couplages

Notre réponse

Modèle RC

MARL / IPPO

PPO + SB3

2. Le Verrou : Simulation vs Apprentissage

Simulation "Black-Box"

- Précision physique maximale
- **Problème :** 1 pas = 1–2 s de calcul
- Impossible pour le RL (10^6 pas)

Modèle "White-Box" (RC)

- Analogie électrique simplifiée
- **Atout :** 10^6 pas en **quelques heures**
- Calibration sur données réelles

Le modèle RC lève le verrou computationnel du RL

3. Modélisation Physique : l'Analogie RC

Équation du bilan thermique — Zone i

$$C_i \frac{dT_i}{dt} = \frac{T_{ext} - T_i}{R_{ext}} + \sum_{j \in \mathcal{N}_i} \frac{T_j - T_i}{R_{i,j}} + Q_{hvac,i}$$

- **C / R :** Inertie et Isolation ($R = e/\lambda S$)

Euler Explicite ($\Delta t = 60$ s)

$$T_i(t + \Delta t) = T_i(t) + \frac{\Delta t}{C_i}\left(\Phi_{ext} + \Phi_{inter} + Q_{hvac,i}\right)$$

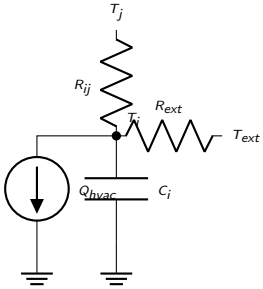

4. Topologie du Bâtiment Multi-Zones

Architecture en étoile

- **Zone 0 (Centre) :** Pièce tampon, pas de contact extérieur.
- **Zone 1 (Nord) :** Offset $-2°C$ (froid).
- **Zone 2 (Sud) :** Offset $+3°C$ (soleil).

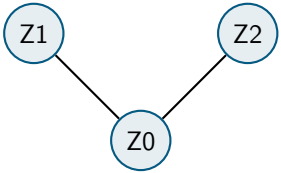

Matrice d'Adjacence A

$$A = \begin{pmatrix} 0 & 1 & 1 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix}$$

5. Formulation du Reinforcement Learning

Espace d'Observation (dim = 5)

- Écart à la consigne ($T_i - T^*$).
- Gradient extérieur ($T_{ext} - T_i$).
- Gradient voisinage ($\bar{T}_{voisins} - T_i$).
- Prix de l'énergie ($p(t)$).
- Nombre de voisins connectés.

Espace d'Action ($[-1, 1]$)

- **Continu :** Commande modulée.
- -1 : Climatisation max.
- $+1$: Chauffage max.

Normalisation

Tous les signaux sont centrés sur zéro pour accélérer la convergence.

6. Reward Engineering : L'Arbitrage Confort/Énergie

Fonction de Récompense (Formulation Elastic Net)

$$r_i = -\frac{1}{20}\left[\alpha \underbrace{\left(|e_i| + e_i^2\right)}_{\text{Inconfort}} + \beta \underbrace{\text{Coût}(t)}_{\text{Énergie}}\right]$$

- **Terme Linéaire ($|e_i|$) :** Sensibilité aux erreurs résiduelles.
- **Terme Quadratique (e_i^2) :** Punition sévère des pics d'inconfort.
- $\alpha, \beta = (2.0, 1.0)$: Priorité au confort thermique.
- **Normalisation** $1/20$: Ramène r_i dans $[-1, 0]$ pour la stabilité.

7. Architecture Actor-Critic

L'Actor (Décideur)

- Sortie : Distribution $\mathcal{N}(\mu, \sigma)$.
- Rôle : Apprendre la meilleure action pour chaque état.

Le Critic (Évaluateur)

- Sortie : Valeur $V(s)$.
- Rôle : Prédire la récompense future pour guider l'Actor.

The Actor/Critic architecture

- **the actor** : update its policy to improve the value given by the critic
- **the critic** : evaluates the actor's policy

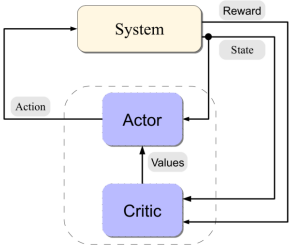

source : [Szepesvári, 2010]

Rémy Degenne | Inria, CRIStAL

8. Algorithme : Proximal Policy Optimization (PPO)

Objectif Clippé : La sécurité de mise à jour

$$L^{CLIP} = \mathbb{E}\left[\min(r_t(\theta)\hat{A}_t, \text{clip}(r_t, 1-\epsilon, 1+\epsilon)\hat{A}_t)\right]$$

- **Ratio $r_t(\theta)$:** Mesure l'écart entre nouvelle et ancienne politique.
- **Clipping ($\epsilon = 0.2$) :** Empêche les changements trop brusques.
- **Stabilité :** Évite que le réseau ne "casse" sa stratégie après un mauvais batch.

9. MARL : Independent PPO via SuperSuit

L'hybridation Multi-Agents

- **Le défi :** Stable-Baselines3 est nativement mono-agent.
- **SuperSuit :** "Aplatit" l'environnement multi-agents en un format vectorisé.
- **IPPO :** Chaque zone a son agent, mais tous partagent le même réseau de neurones.

Avantages

- **Scalabilité :** On peut ajouter des zones sans changer l'IA.
- **Généralisation :** L'agent apprend à gérer tous les types de zones simultanément.

10. Baselines de Contrôle Classique

Régulateur Proportionnel (P)

$$u(t) = K_p \cdot e(t)$$

- **Limite :** Incapable d'annuler l'erreur statique. La consigne n'est jamais atteinte.

Régulateur PI

$$u(t) = K_p e(t) + K_i \int e(t)dt$$

- **Force :** Annule l'erreur.
- **Faiblesse :** Réactif uniquement. Pas d'intelligence sur le coût ou la météo.

Le défi pour l'IA

Le PI est le standard industriel. Battre le PI signifie prouver une économie d'énergie sans sacrifier le confort.

11. Protocole Expérimental

Scénario Estival

$T_{ext} = 35°C, \quad T_{start} = 35°C, \quad T^* = 20°C$

Delta : $-15°C$ à refroidir
2880 pas ($\Delta t = 60\,\text{s}$, soit 48h)

Scénario Hivernal

$T_{ext} = -5°C, \quad T_{start} = 5°C, \quad T^* = 20°C$

Delta : $+15°C$ à chauffer
2880 pas ($\Delta t = 60\,\text{s}$, soit 48h)

3 contrôleurs comparés sur le même scénario fixe

Contrôleur	Paramètres	Caractéristique
Régulateur P	$K_p = 1.0$	Simple, sans mémoire
Régulateur PI	$K_p = 1.0$, $K_i = 0.1$	Anti-windup
PPO (MARL)	10^6 pas, lr$= 10^{-4}$	MlpPolicy, domain rand.

12. Résultats : Scénario Estival ($T_{ext} = 35°C$)

Régulateur P

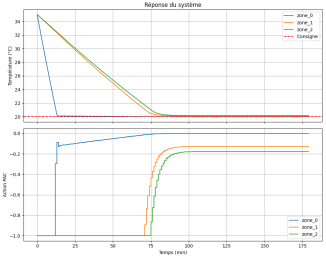

Régulateur PI

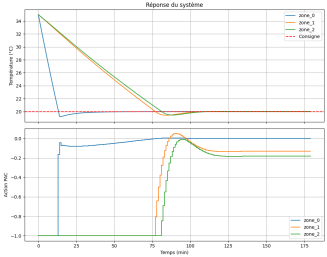

PPO (MARL)

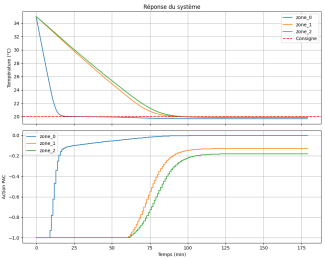

Modèle	Conso (u.a)	T moy	RMSE
PPO	207,2	22,32	4,84
PI	207.8	22,29	4,83
Prop	204.8	22,42	4,83

13. Résultats : Scénario Hivernal ($T_{ext} = -5°C$)

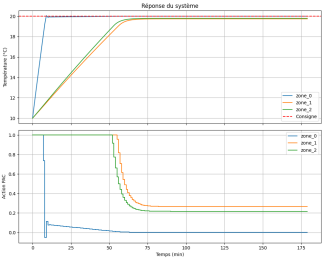

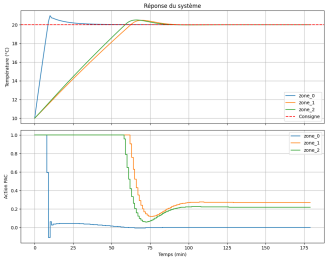

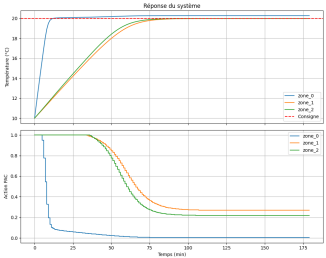

Modèle	Conso (u.a)	T moy	RMSE
PPO	188.97	18,74	2,85
PI	191.09	18,85	2,83
Prop	187.61	18.68	2.84

14. KPIs Consolidés & Mise en Perspective

Table – Comparatif de l'efficacité réelle des modèles (Scénarios Estival et Hivernal)

Modèle	Consommation (u.a)	Temp. Moyenne ($^\circ C$)	Erreur Confort (RMSE)
Scénario Estival			
PPO entraînement long	207,21	22,32	4,84
PPO (Estival)	207,94	**22,28**	4,84
PI (Estival)	207,76	22,29	4,83
Prop (Estival)	**204,81**	22,42	4,83
Scénario Hivernal			
PPO entraînement long	188,97	18,74	2,85
PPO (Hivernal)	190,40	18,82	2,84
PI (Hivernal)	191,09	**18,85**	2,83
Prop (Hivernal)	**187,61**	18,68	2,84

PPO rivalise avec P/PI **sans forecasting** : ni heure, ni météo, T_{ext} constante.

15. Convergence et Apprentissage

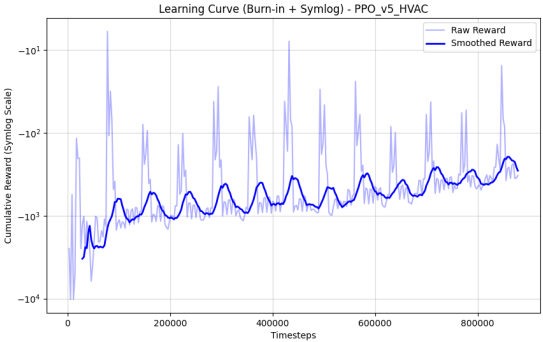

- Entraînement sur **1 000 000 de pas**.
- **Oscillations :** Reflètent l'exploration et l'hétérogénéité des agents.
- **Convergence :** Stabilité atteinte après 600 000 pas.

16. Analyse : L'effet du "Passager Clandestin"

Phénomène de Free-Riding (Zone 0)

L'agent de la Zone 0 (centrale) a appris que ses voisins (Z1 et Z2) chauffent naturellement son espace par conduction.

- **Comportement :** Z0 réduit sa puissance de PAC au minimum.
- **Émergence :** Stratégie optimale pour le score individuel de l'agent Z0.
- **Limite du MARL :** L'optimisation locale peut surcharger les voisins "donneurs".
- **Solution futur :** "Reward Sharing" pour punir l'égoïsme.

17. Conclusion et Perspectives

Bilan du projet

- Modèle RC ultra-rapide fonctionnel.
- IA (PPO) compétitive face au PI.
- Comportements d'anticipation appris.

Perspectives

- Intégrer le forecasting météo.
- Test de l'algorithme SAC (off-policy).
- Reward Engineering (ex : Reward Sharing)

Merci de votre attention !

Questions ?

Soufiane Najari · Encadrant : Pascal YIM · Mars 2026

Parcours SDI · École Centrale de Lille